



Teknoloji Fakültesi

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

AKCİĞER BT GÖRÜNTÜLERİNİN MAKİNE ÖĞRENMESİ ALGORİTMALARIYLA ANALİZİ VE AKCİĞER KANSERİ TESPİTİ

BİTİRME PROJESİ 1. ARA RAPORU

Bilgisayar Mühendisliği Bölümü

"

DANIŞMAN

Doç. Dr. AYŞE BERNA ALTINEL GİRGİN

İSTANBUL, 2025

"

MARMARA ÜNİVERSİTESİ
TEKNOLOJİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Marmara Üniversitesi Teknoloji Fakültesi Bilgisayar Mühendisliği Öğrencileri Sude Nur GÜLCAN, Karun ACAR, Elif TILKI tarafından “AKCİĞER BT GÖRÜNTÜLERİNİN MAKİNE ÖĞRENMESİ ALGORİTMALARIYLA ANALİZİ VE AKCİĞER KANSERİ TESPİTİ ” başlıklı proje çalışması, xxx tarihinde savunulmuş ve jüri üyeleri tarafından başarılı bulunmuştur.

Jüri Üyeleri

Dr. Öğr. Üyesi xxx xxx
Marmara Üniversitesi
Prof. Dr. Xxx xxx
Marmara Üniversitesi
Prof. Dr. Xxx xxx
Marmara Üniversitesi

(Danışman)

(Üye)

(Üye)

(İMZA).....

(İMZA).....

(İMZA).....

ÖNSÖZ

Proje çalışmamız süresince karşılaştığım bütün problemlerde, sabırla yardım ve bilgilerini esirgemeyen, tüm desteğini sonuna kadar yanımda hissettiğim değerli hocalarım, sayın Dr. Öğr. Üyesi Xxx xxx ve sayın Prof. Dr. Xxx xxx' a en içten teşekkürlerimi sunarım.

Bu proje çalışması fikrinin oluşması ve ortaya çıkmasındaki önerisi ve desteğinden dolayı değerli hocam Dr. Öğr. Üyesi Xxx xxx' a teşekkür ederim.

Proje çalışmam sırasında maddi ve manevi desteklerini esirgemeyen okul içerisinde ve okul dışında her zaman yanımda olan değerli çalışma arkadaşlarım ve hocalarım Doç. Dr. Xxx xxx ve Dr. Öğr. Üyesi ' xxx xxx a sonsuz teşekkürlerimi sunarım.

İÇİNDEKİLER

1. GİRİŞ.....	1
1.1. Proje Çalışmasının Amacı ve Önemi.....	2
2. LİTERATÜR TARAMASI.....	2
3. MATERYAL VE YÖNTEM.....	4
3.1. Veri Seti	4
3.2. Metotlar	4
3.2.1. KNN	4
3.2.2. SVM	5
3.2.3. CNN.....	5
4. BULGULAR VE TARTIŞMA.....	7
5. SONUÇLAR.....	16

ÖZET

AKCİĞER BT GÖRÜNTÜLERİNİN MAKİNE ÖĞRENMESİ ALGORİTMALARIYLA ANALİZİ VE AKCİĞER KANSERİ TESPİTİ

Akciğer BT Görüntülerinin Makine Öğrenmesi Algoritmalarıyla Analizi ve Akciğer Kanseri Tespiti başlıklı bu çalışmada, IQ-OTH/NCCD Lung Cancer veri seti kullanılarak akciğer bilgisayarlı tomografi (BT) görüntülerinin derin öğrenme ve geleneksel makine öğrenmesi yöntemleri ile analiz edilmesi ve sınıflandırılması amaçlanmıştır. Veri setinde yer alan görüntüler, normal, malign (kötü huylu) ve benign (iyi huylu) olarak etiketlenmiş olup, ön işleme aşamasında ise, görüntülerin boyutlandırılması, gri tonlamaya dönüştürülmesi ve veri setinin arttırılması gibi işlemler gerçekleştirilerek model eğitime tabi tutulmuştur.

Çalışmada, görüntü sınıflandırma amacıyla Convolutional Neural Network (CNN), Support Vector Machine (SVM) ve K-Nearest Neighbors (KNN) algoritmaları kullanılmış ve modellerin performansları doğruluk, precision, recall ve F1-score gibi performans metrikleri üzerinden karşılaştırılmıştır. Deneysel sonuçlar, farklı sınıflandırma yaklaşımlarının akciğer kanseri teşhisindeki başarısını değerlendirmek ve en uygun yöntemi belirlemek amacıyla analiz edilmiştir. Elde edilen bulgular, derin öğrenme ve geleneksel makine öğrenmesi yöntemlerinin tıbbi görüntü analizi bağlamında etkinliğini ortaya koymakta ve farklı algoritmaların sınıflandırma performansları üzerindeki etkisini karşılaştırmalı olarak değerlendirmek için önemli bir temel sağlamaktadır.

Mart , 2025

Öğrenciler

Sude Nur GÜLCAN

Karun ACAR

Elif TİLKİ

ABSTRACT

ANALYSIS OF LUNG CT IMAGES USING MACHINE LEARNING ALGORITHMS AND LUNG CANCER DETECTION

In this study, titled " Analysis of Lung CT Images Using Machine Learning Algorithms and Lung Cancer Detection," the IQ-OTH/NCCD Lung Cancer dataset was utilized to analyze and classify lung computed tomography (CT) images using deep learning and traditional machine learning methods. The images in the dataset were labeled as normal, malign (cancerous), and benign (non-cancerous). During the preprocessing stage, operations such as resizing the images, converting them to grayscale, and augmenting the dataset were performed before model training. For image classification, Convolutional Neural Network (CNN), Support Vector Machine (SVM), and K-nearest neighbors (KNN) algorithms were employed, and the models' performances were compared based on evaluation metrics such as accuracy, precision, recall, and F1-score. The experimental results were analyzed to assess the effectiveness of different classification approaches in lung cancer detection and to determine the most suitable method. The findings highlight the efficiency of deep learning and traditional machine learning methods in medical image analysis and provide a comparative evaluation of various algorithms' classification performances, serving as a valuable foundation for future research in this domain.

March, 2025

Students

Sude Nur GÜLCAN

Karun ACAR

Elif TILKİ

ŞEKİL LİSTESİ

Şekil 1. KNN Model Doğruluk Metrikleri (%30 Test)	7
Şekil 2. KNN Confusion Matrix (%30 Test).....	8
Şekil 3. KNN Model Doğruluk Metrikleri (%60 Test)	8
Şekil 4. KNN Confusion Matrix (%60 Test).....	8
Şekil 5. SVM Model Doğruluk Metrikleri (%30 Test)	10
Şekil 6. SVM Confusion Matrix (%30 Test).....	10
Şekil 7. SVM Model ROC Eğrisi (%30 Test).....	10
Şekil 8. SVM Model Doğruluk Metrikleri (%60 Test)	11
Şekil 9. SVM Confusion Matrix (%60 Test).....	11
Şekil 10. SVM Model ROC Eğrisi (%60 Test).....	11
Şekil 11. CNN Model Doğruluk Metrikleri (%30 Test)	12
Şekil 12. CNN Confusion Matrix (%30 Test).....	12
Şekil 13. CNN Model Accuracy Grafiği (%30 Test)	13
Şekil 14. CNN Model Loss Grafiği (%30 Test).....	13
Şekil 15. CNN Model Doğruluk Metrikleri (%60 Test)	13
Şekil 16. CNN Confusion Matrix (%60 Test).....	14
Şekil 17. CNN Model Accuracy Grafiği (%60 Test)	14
Şekil 18. CNN Model Loss Grafiği (%60 Test).....	14

TABLO LİSTESİ

Tablo 1. SVM Modelinin Kernel Fonksiyonlara göre Karşılaştırılması	9
Tablo 2. Modellerin Karşılaştırılması	15

1. GİRİŞ

Kanserin küresel çapta görülme sıklığı ve kansere bağlı ölüm oranları her geçen yıl artış göstermektedir [1][2]. Dünya Sağlık Örgütü'nün (WHO) verilerine göre, en yaygın kanser türleri arasında ilk sırada meme kanseri, ikinci sırada ise akciğer kanseri yer almaktadır [3]. Akciğer kanserinin zamanında ve doğru şekilde teşhis edilmesi, hastaların hayatta kalma oranını belirgin şekilde arttırmaktadır [4][5]. Geleneksel tanı yöntemleri, radyologların bilgisayarlı tomografi (BT) ve manyetik rezonans (MR) görüntülerini manuel olarak incelemesine dayanmakta olup, bu süreç hem zaman açısından maliyetli hem de insan hatalarına açık bir yaklaşım sunmaktadır.

Son yıllarda, yapay zekâ ve makine öğrenmesi tabanlı sistemlerin tıbbi görüntü analizinde kullanımının yaygınlaşması, hastalık teşhisinde hekimlere önemli bir destek sağlamaktadır. Derin öğrenme algoritmalarının ilerlemesiyle birlikte, özellikle Evrişimli Sinir Ağları (CNN) gibi modeller, BT ve MR gibi tıbbi görüntüleme yöntemlerinden elde edilen verileri işleyerek akciğer kanseri gibi hastalıkların teşhisinde yüksek doğruluk oranlarına ulaşmaktadır [6]. Dolayısıyla, tıbbi görüntü analizi ve yapay zekâ destekli sınıflandırma yöntemleri, akciğer kanserinin erken teşhisinde kritik bir rol oynamaktadır.

Bu çalışmada ise IQ-OTH/NCCD Lung Cancer Dataset kullanılarak akciğer BT görüntülerinin makine öğrenmesi algoritmaları aracılığıyla analiz edilmesi ve malign durumuna göre sınıflandırılması amaçlanmıştır. Bu bağlamda, makine öğrenmesi temelli tanı sistemlerinin tıbbi görüntü analizi alanındaki etkinliğini ortaya koyarak, akciğer kanseri teşhisinde daha hızlı, güvenilir ve objektif karar destek sistemlerinin geliştirilmesine bilimsel katkı sunması hedeflenmektedir.

1.1 Proje Çalışmasının Amacı ve Önemi

Bu araştırma, makine öğrenmesi tabanlı tanı sistemlerinin tıbbi görüntü analizi alanındaki potansiyelini ortaya koyarak, akciğer kanserinin daha hızlı, güvenilir ve nesnel bir şekilde teşhis edilmesine katkı sunmayı hedeflemektedir. Çalışmanın temel amacı, farklı makine öğrenmesi algoritmalarının sınıflandırma performanslarını analiz ederek en etkili modelin belirlenmesini sağlamaktır. Böylece, elde edilen sonuçlar doğrultusunda geliştirilecek olan modellerin klinik uygulamalara entegre edilerek radyologlara karar destek mekanizması sunması ve akciğer kanseri teşhis sürecinde doğruluğun artırılması hedeflenmektedir.

2. LİTERATÜR TARAMASI

Son yıllarda, tıbbi görüntüleme alanında derin öğrenme ve yapay zeka teknolojilerinin kullanımı önemli bir gelişim göstermiştir. Özellikle akciğer kanseri gibi ciddi hastalıkların erken teşhisinde ve doğru sınıflandırılmasında, bilgisayarla desteklenen görüntü işleme yöntemleri büyük bir potansiyel taşımaktadır. Bu literatür taramasında, akciğer kanseri tespiti ve radyoloji raporu oluşturulmasında kullanılan derin öğrenme teknikleri ve tıbbi görüntüleme uygulamaları incelenmiştir.

R2GenGPT modeli, radyoloji raporu üretiminde büyük dil modellerinin (LLM) potansiyelini optimize etmeye yönelik yapılan önemli bir çalışmadır. Wang ve arkadaşları bu modeli kullanarak görsel özellikleri dil modeli ile hizalayarak, düşük hesaplama karmaşıklığı ve yüksek performans sunmayı başarmıştır. MIMIC-CXR ve IU-Xray veri setlerinde test edilen R2GenGPT, görsel özellikleri sıg, derin ve delta hizalama stratejileriyle entegre ederek, BLEU, ROUGE-L, METEOR ve CIDEr gibi metriklerde üstün performans sergilemiştir. Model, yalnızca hafif bir modül eğitirken LLM parametrelerini dondurarak hızlı yakınsama sağlamış ve klinik etkinlikte diğer yöntemleri geride bırakmıştır. Bu, radyoloji raporu oluşturma otomasyonunun geleceği için önemli bir adımdır [7].

COVID-19 pandemisi ile birlikte, bu hastalığın tanısında kullanılan X-ray ve bilgisayarlı tomografi (BT) görüntülerine dayalı derin öğrenme modelleri de araştırılmaya başlanmıştır. Özellikle CT görüntüleri üzerinde yapılan çalışmalar, virüsün akciğerlerdeki etkilerini tespit etmede önemli bir araç olarak öne çıkmıştır. Derin öğrenme tabanlı CNN modelleri, özellikle COVID-19 tanısında başarılı sonuçlar elde etmiştir. Haryanto ve

arkadaşlarının SCOV CNN modeli kullanarak yapmış olduğu çalışma, CT görüntülerinde yüksek doğruluk oranları ile performans sergileyerek web tabanlı bir sistemle entegre edilmiştir [8]. Bu tür yaklaşımlar, sağlık profesyonellerine tanı koyma süreçlerinde hızlı ve doğru kararlar alabilme yeteneği sunmaktadır.

Ayrıca, akciğer kanseri tespitine yönelik yapılan çalışmalarda, derin öğrenme modellerinin başarılı sonuçlar verdiği gözlemlenmiştir. Ayayna ve arkadaşları, IQOTH/NCCD veri setini kullanarak VGG16 sinir ağı modelini uygulamış ve modelin doğruluğunu %94,19'a çıkarmıştır [9]. Akciğer kanserinin erken evrelerinde doğru tanı koymak için kullanılan transfer öğrenme ve CNN mimarileri, bu tür hastalıkların tedavisinde önemli bir yer tutmaktadır. Aynı şekilde, EfficientNet-B1 ve Vision Transformer (ViT) gibi dönüşüm tabanlı derin öğrenme modelleri, LC25000 veri seti üzerinde yapılan çalışmalarda sırasıyla %96,97 ve %98,4 doğruluk oranlarına ulaşmış ve klinik uygulamalarda güvenilirliklerini artırmıştır [10].

BT görüntülerinde akciğer kanserinin tespiti için segmentasyon ve sınıflandırma yöntemleri de önemli bir yer tutmaktadır. Özdet ve arkadaşının RIDER Lung-CT veri seti üzerinde yaptığı çalışmada, geleneksel eşikleme yöntemleri ve sütunsal tarama algoritmaları kullanılarak yüksek doğruluk oranları elde edilmiştir. Segmentasyon süreci, tümör tespiti için kritik bir öneme sahiptir ve doğru ROI (Region of Interest) çıkarımı, sınıflandırma başarısını doğrudan etkilemektedir [11]. Bu çalışmalar, görüntü işleme tekniklerinin kanser teşhisindeki rolünü vurgulamaktadır.

Son olarak, akciğer kanseri tespitinde kullanılan yeni bir Evrişimsel Sinir Ağı (ESA) modeli, ResNet tabanlı yapısı ve optimize edilmiş parametreleri ile %99 doğruluk oranına ulaşmıştır [6]. Erdoğan ve arkadaşlarının yapmış olduğu çalışma, daha az parametreyle yüksek doğruluk elde etmenin mümkün olduğunu ve klinik uygulamalarda kullanılabilecek güçlü bir model sunduğunu ortaya koymaktadır.

Bu literatür taraması, derin öğrenme ve görüntü işleme yöntemlerinin akciğer kanseri teşhisi ve radyoloji raporu oluşturulmasında nasıl önemli bir rol oynadığını açıkça göstermektedir. Bu alandaki çalışmalar, hem tanı doğruluğunu artırmakta hem de klinik uygulamaların etkinliğini desteklemektedir. Gelecekte yapılacak araştırmalarla bu yöntemlerin daha geniş veri setleri ve daha gelişmiş algoritmalar kullanılarak daha da optimize edilmesi beklenmektedir.

3. MATERYAL VE YÖNTEM

3.1 Veri Seti

Bu çalışmada, Hamdalla F. Al-Yasriy tarafından Kaggle'da yayımlanan IQ-OTH/NCCD akciğer kanseri veri seti kullanılmıştır. Bu veri seti, 2019 yılının sonbahar döneminde, Irak'taki Iraq-Oncology Teaching Hospital ve National Center for Cancer Diseases (IQ-OTH/NCCD) hastanelerinde toplanmış olup farklı evrelerde akciğer kanseri tanısı konmuş hastalara ait bilgisayarlı tomografi (CT) görüntüleri ile sağlıklı bireylerin görüntülerini içermektedir. Veri setinde toplamda 110 vakayı temsil eden 1190 CT tarama dilimi bulunmaktadır. Her bir tarama, değişen sayılarda dilim içermekte olup, her bir dilim, insan göğsünün farklı yön ve açılardan alınan bir kesitini temsil etmektedir. Çalışmaya dahil edilen 110 vakada, cinsiyet, yaş, eğitim durumu, ikamet edilen bölge ve yaşam durumu gibi demografik özellikler açısından çeşitlilik bulunmaktadır. Veri setinde bulunan vakalar üç sınıfa ayrılmaktadır: Normal, Benign (iyi huylu) ve Malign (kötü huylu). Veri seti vakaların sınıfına göre 3 farklı klasörde toplanmıştır. Bu klasörlerde 40 adet Malign vakasına ait 561, 15 adet Benign vakasına ait 120 ve 55 adet Normal vakaya ait 416 görüntü yer almaktadır. CT tarama görüntüleri, Siemens markalı SOMATOM cihazı kullanılarak elde edilmiştir ve DICOM formatında saklanmıştır. Taramalar, nefes tutarak tam inspirasyon anında yapılmıştır. Tüm görüntüler, kimlik bilgisi gizliliğini koruyacak şekilde anonimleştirilmiştir ve bu süreç, katılımcı kurumların etik kurulları tarafından onaylanmıştır [12].

3.2 Metotlar

Bu çalışmada, akciğer kanseri tespiti için farklı makine öğrenimi ve derin öğrenme yöntemleri kullanılmıştır. Kullanılan veri setindeki görüntüler belirli ön işleme adımlarından geçirilerek sınıflandırma modellerine uygun hale getirilmiştir.

3.2.1. KNN

Bu çalışmada, sınıflandırma ve regresyon problemlerinde yaygın olarak kullanılan denetimli bir makine öğrenimi algoritması olan K-En Yakın Komşu (KNN) yöntemi uygulanmıştır. KNN algoritması, verileri belirli bir mesafe metriğine göre en yakın komşularıyla karşılaştırarak tahmin yapmaktadır. En yaygın kullanılan mesafe ölçütleri arasında Öklid mesafesi, Manhattan mesafesi ve Minkowski mesafesi bulunmaktadır [13].

Çalışmada kullanılan veri setindeki görüntüler, ön işleme aşamasında gri tonlamaya çevrilmiş ve 128×128 boyutlarına yeniden ölçeklendirilmiştir. Görüntüler tek boyutlu vektörlere dönüştürülerek her biri 16.384 özellik içeren bir formatta modellenmiştir. Sınıf etiketleri sayısal değerlere çevrildikten sonra MinMaxScaler kullanılarak [0,1] aralığında ölçeklendirme işlemi gerçekleştirilmiştir. Modelin performansını optimize etmek amacıyla GridSearchCV yöntemiyle farklı hiperparametre kombinasyonları test edilerek en iyi parametreler belirlenmiştir. Bu kapsamda $k=3, 5, 7, 9, 11$ komşu sayısı, 'uniform' ve 'distance' ağırlıklandırma yöntemleri, 'auto', 'ball_tree', 'kd_tree' ve 'brute' algoritma seçenekleri, 20, 30, 40 yaprak boyutları, $p=1$ (Manhattan mesafesi) ve $p=2$ (Öklid mesafesi) parametreleri ile farklı kombinasyonlar test edilmiştir. $cv=5$ çapraz doğrulama yöntemiyle gerçekleştirilen bu işlem sonucunda en iyi hiperparametreler 'algorithm': 'auto', 'leaf_size': 20, 'metric': 'minkowski', 'n_neighbors': 3, 'p': 1, 'weights': 'distance' olarak belirlenmiştir.

3.2.2. SVM

Çalışmada kullanılan bir diğer yöntem ise, veri noktalarını optimal olarak ayıran hiper düzlemi belirleyerek sınıflandırma yapan güçlü bir algoritma olan Destek Vektör Makineleri (SVM) olmuştur. SVM' nin temel amacı, verileri maksimum marjine sahip bir hiper düzlemle ayırmaktır. Model, çekirdek (kernel) fonksiyonları sayesinde doğrusal olmayan verileri daha yüksek boyutlara taşıyarak sınıflandırmayı mümkün kılmaktadır. En yaygın kullanılan çekirdek fonksiyonları doğrusal (linear) kernel, RBF (Radial Basis Function) kernel, polynomial kernel ve sigmoid fonksiyonlarıdır [14].

Çalışmada linear, RBF ve polynomial olmak üzere üç farklı çekirdek fonksiyonu kullanılmıştır. Veri setindeki görüntüler gri tonlamaya çevrilmiş, 128×128 boyutlarına ölçeklendirilmiş ve düzleştirilmiştir. Normal, benign (iyi huylu) ve malign (kötü huylu) olmak üzere üç farklı sınıfa ayrılan veriler, modelin daha iyi genelleme yapabilmesi için homojen hale getirilmiştir.

3.2.3. CNN

Son olarak, görsel veriler üzerinde etkili çalışabilen özel bir yapay sinir ağı mimarisi olan Evrişimli Sinir Ağları (CNN) modeli de çalışmada kullanılmıştır. CNN, görüntüyü küçük ve örtüşen bölgelere ayırarak bu bölgelerdeki öne çıkan özellikleri öğrenen bir dizi evrişim katmanından meydana gelmektedir.

Bu katmanlar, girdi görüntülerde belirli desenleri tanımlayan özellikleri çıkarırken, evrişim ve havuzlama katmanları ise özellik haritalarını oluşturup aynı zamanda boyutu küçültürken öğrenme sürecinde kullanılan parametre sayısını azaltmaktadır. Böylece ağ, daha karmaşık özellikleri verimli bir şekilde öğrenebilmektedir. CNN'ler nesne tanıma, yüz tanıma ve çeşitli görsel analiz görevlerinde yaygın olarak uygulanmaktadır [15].

Geliştirilen derin öğrenme tabanlı CNN (Convolutional Neural Network) modeli, çeşitli boyutlardaki evrişim katmanları ve Batch Normalization işlemleriyle optimize edilerek görüntü özelliklerini etkin bir şekilde öğrenmek üzere tasarlanmıştır. Maksimum havuzlama (Max Pooling) katmanları ile boyut küçültme sağlanırken, tam bağlantılı (Fully Connected) katmanlarla sınıflandırma gerçekleştirilmiştir. Model, $224 \times 224 \times 3$ boyutlarındaki giriş görüntülerini kabul etmekte olup, ilk konvolüsyon katmanında 128 filtre, 8×8 kernel boyutu ve 3×3 adım (stride) kullanarak temel özellikleri çıkarmaktadır. Bu katmanda doğrusal olmayan ilişkilerin modellenmesi için ReLU aktivasyon fonksiyonu tercih edilmekte ve Batch Normalization ile ağırlık öğrenme süreci hızlandırılıp optimize edilmektedir. İkinci konvolüsyon katmanında, 256 filtre ile 5×5 kernel boyutu kullanılarak konvolüsyon işlemi gerçekleştirilmekte ve padding="same" parametresi ile giriş ve çıkış boyutları korunmaktadır. Ardından, Batch Normalization işlemi uygulanmakta ve MaxPooling (3×3 havuzlama) katmanı ile en önemli özellikler öne çıkarılmaktadır. Bu işlemin ardından, üç ardışık konvolüsyon katmanı sırasıyla 3×3 ve 1×1 kernel boyutlarıyla uygulanarak daha derin özelliklerin öğrenilmesi sağlanmaktadır.

Devam eden katmanlarda, 512 filtre ve 3×3 kernel boyutu kullanılarak özellik haritaları daha da detaylandırılmakta ve her bir konvolüsyon katmanından sonra Batch Normalization ile ağırlıkların dengelenmesi sağlanmaktadır. Ara katmanlarda uygulanan MaxPooling (2×2 havuzlama) işlemi, gereksiz bilgilerin filtrelenmesi ve modelin işlem verimliliğinin artırılması amacıyla kullanılmaktadır. Modelin çıkış katmanına geçilmeden önce, konvolüsyonel özellik haritaları Flatten katmanı ile tek bir vektöre dönüştürülüp ardından iki adet 1024 nöronlu tam bağlı (Dense) katman eklenmiştir. Aşırı öğrenmeyi önlemek amacıyla her iki Dense katmanına %50 Dropout uygulanmıştır. Son olarak, 3 nöronlu çıkış katmanı ile softmax aktivasyon fonksiyonu kullanılarak modelin üç sınıf arasında olasılıksal tahmin yapması sağlanmıştır.

Modelin eğitimi sırasında, 10 epoch boyunca Stokastik Gradyan İnişi (SGD) optimizier kullanılarak modelin doğruluk ve kayıp değerleri optimize edilmiştir.


Çalışma kapsamında kullanılan tüm modellerin performansı, doğruluk, hassasiyet ve F1-skora dayalı olarak değerlendirilmiş ve karşılaştırılmıştır. Elde edilen sonuçlar, akciğer kanseri teşhisi için en uygun modelin belirlenmesi amacıyla analiz edilmiştir.

4. BULGULAR VE TARTIŞMA

Modellerin performans analizi incelendiğinde, farklı veri seti ayrımları ve model türlerinin sonuçlar üzerindeki etkisi belirgin bir şekilde gözlemlenmiştir. KNN modelinde, veri seti %70 eğitim ve %30 test olarak ayrıldığında %99.09 doğruluk oranı elde edilmiştir. Bu yüksek performans, modelin genel olarak doğru sınıflandırma yaptığını gösterirken, yanlış sınıflandırmaların çoğunlukla benign sınıfında (3 hata) gerçekleştiği ve diğer sınıflarda hata oranının sıfıra yakın olduğu dikkat çekmiştir. Veri seti %40 eğitim ve %60 test olarak ayrıldığında doğruluk oranı %94.39'a düşmüş, bu da eğitim verisi azaldığında model performansında düşüş olduğunu göstermiştir. Eğitim seti büyüdükçe modelin genelleme kapasitesinin arttığı, ancak eğitim seti küçüldüğünde bazı sınıflarda F1-score değerlerinin düştüğü gözlemlenmiştir. KNN modelinin sonuçlarına ait tablolar ve görseller aşağıda yer almaktadır:

Test Doğruluğu: 99.09%					
	precision	recall	f1-score	support	
0	1.00	0.93	0.96	40	
1	1.00	1.00	1.00	174	
2	0.97	1.00	0.99	116	
accuracy			0.99	330	
macro avg	0.99	0.97	0.98	330	
weighted avg	0.99	0.99	0.99	330	

Şekil 1. KNN Model Doğruluk Metrikleri (%30 Test)

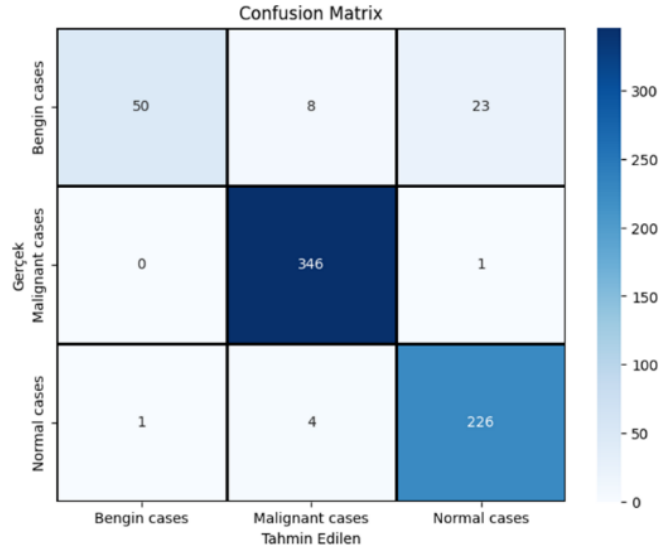


Şekil 2. KNN Confusion Matrix (%30 Test)

Test Doğruluğu: 94.39%

	precision	recall	f1-score	support
0	0.98	0.62	0.76	81
1	0.97	1.00	0.98	347
2	0.90	0.98	0.94	231
accuracy			0.94	659
macro avg	0.95	0.86	0.89	659
weighted avg	0.95	0.94	0.94	659

Şekil 3. KNN Model Doğruluk Metrikleri (%60 Test)



Şekil 4. KNN Confusion Matrix (%60 Test)

SVM modelinde, 0.3 test oranı ile yapılan denemelerde linear ve poly çekirdek fonksiyonları en yüksek doğruluk oranlarına ulaşarak %99.39 doğruluk elde etmişlerdir. Linear çekirdek fonksiyonu, "Normal", "Benign" ve "Malign" sınıflarında sırasıyla %0.99 ve %1.00 precision değerleri sunarken, poly çekirdek fonksiyonu çapraz doğrulama ortalamasıyla %99.48 gibi daha yüksek bir sonuç göstermiştir. RBF çekirdek fonksiyonu ise %96.06 doğruluk oranı ile diğer çekirdeklerin gerisinde kalmış ve "Malign" sınıfında daha düşük precision değerleriyle dikkat çekmiştir. 0.6 test oranında yapılan denemelerde ise poly çekirdek fonksiyonu %96.97 doğruluk ile en iyi sonucu verirken, linear çekirdek fonksiyonu %96.81 doğruluk oranıyla hemen ardından gelmiştir. Linear çekirdek, "Malign" ve "Benign" sınıflarında %1.00 precision değerlerine ulaşsa da, "Normal" sınıfında %0.93'e düşmüştür. RBF çekirdek fonksiyonu ise %88.47 doğruluk oranıyla en düşük performansı sergilemiştir. Genel olarak, test oranının artmasıyla doğruluk oranlarının yükseldiği, ancak çekirdek fonksiyonlarının farklı test oranlarında farklı performanslar gösterdiği anlaşılmıştır. SVM modelinin sonuçlarına ait tablolar ve görseller aşağıda yer almaktadır:


Tablo 1. SVM Modelinin Kernel Fonksiyonlara göre Karşılaştırılması

Çekirdek Fonksiyonu	Test Oranı	Model Doğruluğu (%)	Normal Precision	Benign Precision	Malignant Precision
Linear	0.3	99.39	0.99	1.00	0.99
RBF	0.3	96.06	0.96	1.00	0.95
Poly	0.3	99.39	0.99	1.00	0.99
Linear	0.6	96.81	0.93	1.00	1.00
RBF	0.6	88.47	0.81	1.00	0.95
Poly	0.6	96.97	0.93	1.00	1.00


Model Accuracy: 99.39%

	precision	recall	f1-score	support
Normal	0.99	0.99	0.99	127
Benign	1.00	0.97	0.99	38
Malignant	0.99	1.00	1.00	165
accuracy			0.99	330
macro avg	1.00	0.99	0.99	330
weighted avg	0.99	0.99	0.99	330

Şekil 5. SVM Model Doğruluk Metrikleri (%30 Test)



Şekil 6. SVM Confusion Matrix (%30 Test)




Şekil 7. SVM Model ROC Eğrisi (%30 Test)

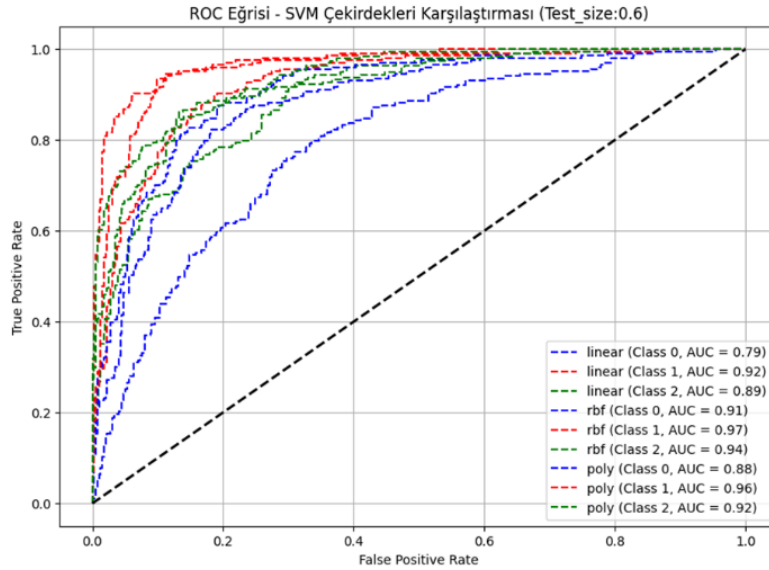
Model Accuracy: 96.97%

	precision	recall	f1-score	support
Normal	0.93	1.00	0.96	257
Benign	1.00	0.78	0.88	82
Malignant	1.00	1.00	1.00	320
accuracy			0.97	659
macro avg	0.98	0.92	0.95	659
weighted avg	0.97	0.97	0.97	659

Şekil 8. SVM Model Doğruluk Metrikleri (%60 Test)



Şekil 9. SVM Confusion Matrix (%60 Test)



Şekil 10. SVM Model ROC Eğrisi (%60 Test)


CNN modeli ile yapılan deneylerde, eğitim veri oranı %70 olduğunda modelin doğruluk oranı %96.1 olarak ölçülmüştür. Malign sınıfı için %98 precision ve %100 recall değerleri elde edilmiş, bu da modelin kötü huylu vakaları eksiksiz tespit ettiğini göstermektedir. Ancak benign sınıfta %100 precision ve %68 recall değeri elde edilerek, modelin bazı benign vakaları yanlış negatif olarak sınıflandırdığı gözlemlenmiştir. Normal sınıfta ise %92 precision ve %100 recall değeriyle modelin genel performansının yüksek olduğu görülmüştür. Eğitim oranı %40'a düşürüldüğünde de modelin genel doğruluk oranı %96.1 olarak kalmıştır.

Ancak benign ve normal sınıflarında recall değerlerinin arttığı ve yanlış negatiflerin azaldığı tespit edilmiştir. Malign sınıfta ise precision %99, recall %100 ve F1-score %100 olarak ölçülerek modelin bu sınıfta en yüksek performansı gösterdiği belirlenmiştir. CNN modelinin sonuçlarına ait tablolar ve görseller aşağıda yer almaktadır:


	precision	recall	f1-score	support
Benign	1.00	0.68	0.81	40
Malignant	0.98	1.00	0.99	174
Normal	0.92	1.00	0.96	116
accuracy			0.96	330
macro avg	0.97	0.89	0.92	330
weighted avg	0.96	0.96	0.96	330

Accuracy of the Model: 96.1%


Şekil 11. CNN Model Doğruluk Metrikleri (%30 Test)



Şekil 12. CNN Confusion Matrix (%30 Test)



Şekil 13. CNN Model Accuracy Grafiği (%30 Test)




Şekil 14. CNN Model Loss Grafiği (%30 Test)


	precision	recall	f1-score	support
Benign	1.00	0.91	0.95	81
Malignant	0.99	1.00	1.00	347
Normal	0.98	1.00	0.99	231
accuracy			0.99	659
macro avg	0.99	0.97	0.98	659
weighted avg	0.99	0.99	0.99	659

Accuracy of the Model: 98.8%


Şekil 15. CNN Model Doğruluk Metrikleri (%60 Test)



Şekil 16. CNN Confusion Matrix (%60 Test)



Şekil 17. CNN Model Accuracy Grafiği (%60 Test)



Şekil 18. CNN Model Loss Grafiği (%60 Test)

Tablo 2. Modellerin Karşılaştırılması

Train – Test Oranı/ Algoritma	KNN Doğruluk (%)	SVM Doğruluk (%)	CNN Doğruluk (%)
70/30	99.09	99.39	96.1
40/60	94.39	96.97	98.8

Sonuç olarak, KNN, SVM ve CNN modelleri farklı veri seti ayrımları altında incelendiğinde, eğitim ve test oranlarının değişmesiyle doğruluk oranlarında ve metriklerde farklılıklar ortaya çıkmıştır. KNN modeli, eğitim seti büyük olduğunda daha yüksek doğruluk göstermiştir. SVM modeli, linear ve poly çekirdek fonksiyonlarının test oranına bağlı olarak yüksek doğruluk oranları sunduğunu ortaya koyarken, RBF çekirdek fonksiyonu her iki test oranında da daha düşük performans göstermiştir. CNN modeli ise her iki veri seti ayrımında da yüksek doğruluk oranını korumuş, ancak sınıf bazında precision ve recall değerlerinde küçük farklılıklar gözlemlenmiştir. Bu bulgular, model performansının veri seti ayrımlarına ve model türlerine göre nasıl değişebileceğini ve farklı senaryolarda hangi modelin daha uygun olduğunu göstermektedir.

Gelecekte, CNN modeli ile devam edilmesi planlanmaktadır. Model performanslarını artırmak ve yanlış sınıflandırmaları en aza indirmek amacıyla çeşitli iyileştirme çalışmaları gerçekleştirilecektir. Derin öğrenme bağlamında, CNN modelinin sınıflandırma performansını artırmak adına farklı optimizasyon algoritmaları ve aktivasyon fonksiyonları denenerek modelin duyarlılığı ve doğruluğu iyileştirilecektir. Ayrıca, VGG16 ve ResNet gibi önceden eğitilmiş derin öğrenme modelleri kullanılarak transfer öğrenme yöntemleri uygulanacak ve böylece modelin daha güçlü bir genelleme kapasitesine sahip olması sağlanacaktır. Bununla birlikte, mevcut modellerin yalnızca iyileştirilmesiyle sınırlı kalınmayarak, yeni derin öğrenme mimarilerinin tasarlanması ve farklı model kombinasyonlarının denenmesi planlanmaktadır. Bu çalışmaların sonucunda, daha güvenilir ve yüksek doğruluğa sahip sınıflandırma sistemlerinin geliştirilmesi hedeflenmektedir.

5. SONUÇLAR

Bu çalışma, akciğer kanseri tespiti gibi kritik bir alanda yapay zekânın potansiyelini ortaya koyarak, KNN, SVM ve CNN gibi farklı makine öğrenmesi yöntemlerinin etkinliğini gözler önüne sermiştir. Modellerin performans analizi incelendiğinde, SVM ve CNN modellerinin öne çıktığı görülmüştür. Özellikle SVM modelinin linear ve poly çekirdek fonksiyonları ile %99.39'a varan doğruluk oranlarına ulaşması, bu modelin genelleme kapasitesini ortaya koymaktadır. CNN modeli ise malign sınıfta elde ettiği %99 precision, %100 recall ve %100 F1-score değerleri ile kötü huylu vakaları tespit etmede çok başarılı olduğunu göstermiştir.

Performans analizleri, veri seti büyüdükçe modellerin genelleme kabiliyetinin arttığını, ancak az veriyle çalışıldığında bazı modellerde önemli düşüşler yaşandığını ortaya koymuştur. Bu durum, makine öğrenmesi modellerinin geliştirilmesi ve tıbbi uygulamalarda etkin bir şekilde kullanılmasında veri kalitesi ile miktarının kritik bir rol oynadığını göstermektedir.

Proje sonucunda, derin öğrenme ve geleneksel makine öğrenmesi algoritmalarının tıbbi görüntü analizindeki etkinliği doğrulanmış ve klinik karar destek sistemlerine entegrasyon potansiyeli incelenmiştir. Gelecekteki çalışmalar için, daha geniş veri setleri ve daha karmaşık modeller kullanılarak tıbbi görüntü analizindeki sınıflandırma performansının artırılabilirliği öngörülmektedir. Bu çerçevede, projeden elde edilen bulguların, tıbbi tanı süreçlerinin hızlandırılması ve iyileştirilmesi amacıyla önemli bir katkı sağlayacağı düşünülmektedir.

KAYNAKLAR

- [1] A. PAVLOPOULOU, D. A. SPANDIDOS, and I. MICHALOPOULOS, “Human cancer databases (Review),” *Oncology Reports*, vol. 33, no. 1, pp. 3–18, Oct. 2014, doi: <https://doi.org/10.3892/or.2014.3579>.
- [2] R. L. Siegel, K. D. Miller, and A. Jemal, “Cancer statistics, 2016,” *CA: A Cancer Journal for Clinicians*, vol. 66, no. 1, pp. 7–30, Jan. 2016.
- [3] World Health Organization, “Cancer,” *World Health Organization*, Feb. 03, 2025. <https://www.who.int/news-room/fact-sheets/detail/cancer>
- [4] V. Gant and R. Dybowski, *Clinical Applications of Artificial Neural Networks*. Cambridge University Press, 2001. doi: <https://doi.org/10.1017/cbo9780511543494>.
- [5] Azzam Taktak, “The use of artificial neural networks in decision support in cancer: A systematic review,” *Neural Networks*, 2006. https://www.academia.edu/13719857/The_use_of_artificial_neural_networks_in_decision_support_in_cancer_A_systematic_review (accessed Mar. 22, 2025).
- [6] M. Nur, Tülin ÖZTÜRK, and M. TALO, “Yeni bir Evrişimsel Sinir Ağı Modeli Kullanarak Bilgisayarlı Tomografi Görüntülerinden Akciğer Kanseri Tespiti,” *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, vol. 34, no. 2, pp. 795–802, Sep. 2022, doi: <https://doi.org/10.35234/fumbd.1135691>.
- [7] Z. Wang, L. Liu, L. Wang, and L. Zhou, “R2GenGPT: Radiology Report Generation with Frozen LLMs,” *Meta-radiology*, vol. 1, no. 3, pp. 100033–100033, Nov. 2023, doi: <https://doi.org/10.1016/j.metrad.2023.100033>.
- [8] T. Haryanto, Heru Suhartanto, Aniati Murni, Kusmardi Kusmardi, and J. M. Zain, “SCOV-CNN: A Simple CNN Architecture for COVID-19 Identification Based on the CT Images,” *JOIV International Journal on Informatics Visualization*, vol. 8, no. 1, Mar. 2024, doi: <https://doi.org/10.62527/joiv.8.1.1750>.

- [9] Ferhat Ayayna, Abidin Çalışkan, and A. Aslan, “Akciğer Kanserinin Derin Öğrenme Yaklaşımları Kullanılarak Tespit Edilmesi,” *International Conference on Scientific and Academic Research (ICSAR’22)*, Dec. 2022, Available: https://www.researchgate.net/publication/366464730_Akciger_Kanserinin_Derin_Ogrenme_Yaklasimlari_Kullanilarak_Tespit_Edilmesi
- [10] D. Şeker, M. S. Kartal, A. Yıldız, and I. Öksüz, “Akciğer Kanseri tespitinde Dönüşüm ve Evrişim Tabanlı modeller İle Açıklanabilir Yapay Zeka Uygulaması,” *EMO Bilimsel Dergi*, <https://dergipark.org.tr/tr/pub/emobd/issue/86413/1484039> (accessed Mar. 23, 2025).
- [11] Berat ÖZDET and Semra İÇER, “AKCİĞER BİLGİSAYARLI TOMOGRAFİ GÖRÜNTÜLERİNDE GÖRÜNTÜ İŞLEME UYGULAMALARI İLE TUMÖRLERİNİN TESPİT EDİLMESİ,” *Deleted Journal*, pp. 135–150, Mar. 2022, doi: <https://doi.org/10.17482/uumfd.947619>.
- [12] “The IQ-OTH/NCCD lung cancer dataset,” *www.kaggle.com*. <https://www.kaggle.com/datasets/hamdallak/the-iqothnccd-lung-cancer-dataset>
- [13] S. Zhang, “Challenges in KNN Classification,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 34, no. 10, pp. 1–1, 2021, doi: <https://doi.org/10.1109/tkde.2021.3049250>.
- [14] Yrd Doç, Emre Yakut, Bekir Elmas, S. Yavuz, and Destek Vektör Makineleri, “Yapay Sinir Ağları ve Destek Vektör Makineleri Yöntemleriyle Borsa Endeksi Tahmini,” Jan. 01, 2014. https://www.researchgate.net/publication/349027298_Yapay_Sinir_Aglari_ve_Destek_Vektor_Makineleri_Yontemleriyle_Borsa_Endeksi_Tahmini
- [15] Y. Özüpak, “Evrişimli Sinir Ağı (ESA) Mimarileri ile Hücre Görüntülerinden Sıtmanın Tespit Edilmesi,” *Çukurova Üniversitesi Mühendislik Fakültesi Dergisi*, vol. 39, no. 1, pp. 197–210, Mar. 2024, doi: <https://doi.org/10.21605/cukurovaumfd.1460434>.